

Մեքենայական ուսուցումից մինչև PCA



Դասի ճանապարհային քարտեզ

Սկսում ենք ընդհանուր ՄՈՒ-ից, հետո խորանում PCA-ի քայլերի մեջ

1. Ի՞նչ է մեքենայական ուսուցումը

2. Վերահսկվող / չվերահսկվող / ամրապնդմամբ ուսուցում

3. Չափողականության կրճատման խնդիրն ու կիրառությունները


4. PCA-ի մաթեմատիկան՝ միջին, դիսպերսիա, կովարիացիա, սեփական վեկտոր

5. Ձեռքով օրինակ և Python իրականացում

Ի՞նչ է մեքենայական ուսուցումը

ՄՈՒ-ն սովորեցնում է համակարգին օրինաչափություն գտնել տվյալներից

- Սովորական ծրագրում մարդը գրում է կանոնները:
- ՄՈՒ-ում մենք տալիս ենք օրինակներ, իսկ մոդելը սովորում է օրինաչափություն:
- Մոդելը հետո օգտագործվում է նոր, չտեսած տվյալների վրա:



օրինակներ → օրինաչափություն → որոշում

Տվյալների լեզու. նմուշ, հատկանիշ, թիրախ


Նմուշ	հատկանիշ 1	հատկանիշ 2	թիրախ
տոուն A	80 մ ²	կենտրոն	75 մլն
տոուն B	45 մ ²	արվարձան	32 մլն
տոուն C	120 մ ²	կենտրոն	?

- Նմուշ՝ մեկ օբյեկտ կամ դեպք
- Հատկանիշ՝ թիվ/տեքստ, որը նկարագրում է նմուշը
- Թիրախ՝ պատասխանը, եթե այն ունենք

$X \in \mathbb{R}^{n \times d}$, y ՝ թիրախների վեկտոր

ՄՈՒ-ի հիմնական ուղղությունները


Խնդրի ձևը որոշում է ուսուցման տեսակը



Կիսավերահսկվող և ինքնավերահսկվող մեթոդները հաճախ միջանկյալ կամ հատուկ դեպքեր են

Վերահսկվող ուսուցում

Տվյալներ + ճիշտ պատասխան $\rightarrow$ սովորում ենք կանխատեսել




- Օրինակներ՝ գնի կանխատեսում, հիվանդության ռիսկ, սպամի հայտնաբերում
- Սխալը չափում ենք՝ $\hat{y}$ -ը համեմատելով y -ի հետ
- Նպատակը՝ լավ աշխատել ոչ միայն հիշած, այլև նոր տվյալների վրա

Վերահսկվող ռեգրեսիա

Երբ պատասխանը թիվ է

- Թիրախը շարունակական մեծություն է՝ գին, ջերմաստիճան, միավոր:
- Մոդելը սովորում է կապը հատկանիշների և թվի միջև:
- Պարզ օրինակ՝ ուղիղ գիծ տվյալների միջով:

$$y \approx kx + b$$




Վերահսկվող դասակարգում

Երբ պատասխանը կատեգորիա է


- Թիրախը դաս է՝ սպամ/ոչ սպամ, կատու/շուն, անցավ/չանցավ:
- Մոդելը սովորում է որոշման սահման:
- Սխալը՝ սխալ դասի ընտրությունն է:

$$\hat{y} \in \{\text{դաս 1, դաս 2, ...}\}$$



Զվերահսկվող ուսուցում

Տրված են միայն X տվյալները. պատրաստի պատասխաններ չկան




- Կլաստերացում՝ գտնել նման օբյեկտների խմբեր:
- Չափողականության կրճատում՝ շատ հատկանիշներ → քիչ կոորդինատներ:
- PCA-ն չվերահսկվող գծային չափողականության կրճատում է:


Չվերահսկվող կլաստերացում

Նման կետերը հավաքվում են նույն խմբում

- Օրինակ՝ հաճախորդների հատվածավորում:
- Խմբերը նախապես չեն տրված:
- Արդյունքը պետք է մեկնաբանել խնդրի համատեքստում:



Չափողականության կրճատումը ՄՈՒ քարտեզում



$$\mathbf{X} \in \mathbb{R}^{n \times d} \rightarrow \mathbf{Z} \in \mathbb{R}^{n \times k}, \quad k < d$$

- Նմուշների թիվը՝ n , սովորաբար չի փոխվում
- փոխվում է հատկանիշների/կոորդինատների թիվը՝ d -ից k

Ի՞նչ է չափողականությունը

Չափողականությունը հատկանիշների թիվն է

d սյուն = հատկանիշներ



**28×28
պատկեր**

**784
պիքսելային
հատկանիշ**

n տող = նմուշներ


$$d = 784$$

- Եթե նկարն ունի շատ պիքսել, այն մեծ չափանի վեկտոր է:
- PCA-ն փորձում է այդ երկար վեկտորը ներկայացնել քիչ թվերով:

Ինչո՞ւ կրճատել չափողականությունը

Բարձր չափերում դժվար է տեսնել, պահել և սովորել

3D ամպ. ուղղում ենք տեսնել 2D-ում



- Տեսապատկերում՝ 100 կամ 784 հատկանիշը չենք կարող ուղիղ նկարել:
- Սեղմում՝ նույն տեղեկությունը պահել ավելի քիչ թվերով:
- Աղմուկի նվազեցում՝ երբ փոքր դիսպերսիայի ուղղությունները հիմնականում աղմուկ են:
- Արագացում՝ հաջորդ մոդելը կարող է աշխատել ավելի քիչ հատկանիշով:

Բայց չափազանց մեծ կրճատումը կարող է կորցնել օգտակար ազդանշանը

Կիրառություններ

Չափողականության կրճատումը օգնում է տարբեր նպատակների համար

**Տեսապատկերում
բարձր չափանի տվյալը նկարել 2D/3D-ում**

**Սեղմում
պահել քիչ թվեր, մոտավոր
վերականգնել**

**Գերհարմարեցման նվազեցում
քիչ հատկանիշով հետագա մոդելը պարզ
է**

**Բացակայող արժեքներ
ցածր ռանգով վերականգնումը կարող է
օգնել լրացման մեջ**

Կցված նյութի PCA սլայդում նշվում են visualization, feature selection և data imputation կիրառությունները:

Հատկանիշների ընտրություն, թե՞ արտածում

PCA-ն սովորաբար ստեղծում է նոր հատկանիշներ

Ընտրություն
պահում ենք սկզբնական
սյունակների մի մասը




Արտածում
ստեղծում ենք նոր
համակցություններ

PCA = feature extraction

$$z = 0.7 \cdot x_1 + 0.7 \cdot x_2$$

PCA-ի ինտուիցիան. գտնել երկար առանցքը

Լավ առանցքը պահում է կետերի տարածվածությունը



- Կետերը ձգված են մեկ թեք ուղղությամբ:
- Եթե պահենք այդ ուղղության կոորդինատը, քիչ տեղեկություն կկորցնենք:
- PCA-ն ընտրում է մեծագույն դիսպերսիայի ուղղությունը:

առաջին գլխավոր բաղադրիչ = PC1

Մաթեմատիկական գաղափար 1. միջին և դիսպերսիա

Միջինը ցույց է տալիս կենտրոնը, դիսպերսիան՝ տարածվածությունը

$$\mu = (x_1 + x_2 + \dots + x_n) / n$$

միջին = կենտրոն


$$\text{Var}(x) = \sum (x_i - \mu)^2 / (n - 1)$$

**դիսպերսիա = որքան են
կետերը ցրված կենտրոնից**

- PCA-ն սիրում է այն ուղղությունները, որտեղ դիսպերսիան մեծ է:
- Մեծ դիսպերսիա $\neq$ միշտ կարևոր է թիրախի համար, բայց PCA-ի չափանիշը դա է:

Մաթեմատիկական գաղափար 2. գաուսյան բաշխում

Չանգաձև ամպ, որի ձևը նկարագրվում է միջինով և կովարիացիայով



- 1D-ում գաուսյանը զանգի նման բաշխում է:
- 2D-ում այն հաճախ երևում է որպես էլիպսաձև կետերի ամպ:
- Էլիպսի երկար առանցքը ցույց է տալիս մեծ դիսպերսիայի ուղղությունը:
- PCA-ն պարտադիր չի պահանջում գաուսյանություն, բայց այս պատկերը օգնում է հասկանալ երկրաչափությունը:

$$N(\mu, C)$$

Մաթեմատիկական գաղափար 3. Կովարիացիա

Կովարիացիան չափում է՝ երկու հատկանիշները միասին են փոխվում

$$\text{Cov}(x,y) = \Sigma(x_i - \mu_x)(y_i - \mu_y) / (n - 1)$$

դրական
մեծ x-ի հետ հաճախ մեծ
y



բացասական
մեծ x-ի հետ հաճախ
փոքր y

մոտ զրո
գծային կապը թույլ է

- Կովարիացիան կախված է չափման միավորներից:
- Կոռելյացիան կովարիացիայի սանդղակված տարբերակն է՝ -1-ից 1:

Մաթեմատիկական գաղափար 4. Կովարիացիայի մատրից

Բոլոր զույգ կապերը դրվում են մեկ աղյուսակի մեջ



անկյունագիծ =
դիսպերսիաներ

անկյունագծից դուրս
= կովարիացիաներ

PCA քայլ 1. կենտրոնացնել և երբեմն ստանդարտացնել

PCA-ն ուսումնասիրում է շեղումները միջինից

$$X_{ci} = X_i - \mu$$

կենտրոնացում
յուրաքանչյուր սյան միջինը
դարձնում է 0

$$\text{ստանդարտացում} \quad (X_i - \mu) / s$$


ստանդարտացում
օգնում է, երբ միավորները
տարբեր են

- Նոր տվյալների վրա օգտագործում ենք նույն μ -ն և s -ը, որոնք սովորել ենք train-ից:
- Օրինակ՝ դրամը և տարիքը նույն սանդղակի վրա չեն:

Մաթեմատիկական գաղափար 6. սեփական վեկտոր և արժեք

Սեփական վեկտորը ձևափոխումից հետո մնում է նույն ուղղի վրա

Սեփական վեկտորները չեն փոխում իրենց ուղիղը



$$A v = \lambda v, \quad v \neq 0$$

- v ` սեփական վեկտոր` հատուկ ուղղություն:
- λ ` սեփական արժեք` որքան է ձգվում կամ սեղմվում:
- PCA-ում C -ի սեփական վեկտորները դառնում են գլխավոր առանցքներ:
- Մեծ λ նշանակում է մեծ դիսպերսիա այդ ուղղությամբ:

Տեսենք սեփական վեկտորների շարժումը

3Blue1Brown տեսանյութ ինտուիցիայի համար

Դիտելիս գտեք՝ որ վեկտորներն են մնում իրենց ուղղի վրա


<https://www.youtube.com/watch?v=PFDu9oVAE-g>

Առաջարկ՝ դիտել մոտ 4 րոպե այն հատվածից, որտեղ ցանցը ձևափոխվում է և երևում են սեփական ուղղությունները:

**Հարց քննարկման համար. Ն-ն ի՞նչ է ասում երկարության
մասին**

PCA-ի նպատակը բանաձևով

Ընտրել ուղղություն, որտեղ պրոյեկցիաների դիսպերսիան մեծագույնն է




$$\text{maximize } \text{Var}(Xc w) = w^T C w$$

$$\text{պայման } \|w\| = 1$$

- Առանց $\|w\|=1$ պայմանի կարող ենք w -ը մեծացնել և դիսպերսիան անվերջ մեծացնել:
- Այդ պատճառով որոնում ենք միայն ուղղություններ, ոչ երկարություններ:

Մի քանի գլխավոր բաղադրիչ

PC2-ը մեծագույն դիսպերսիա ունի PC1-ին ուղղահայաց ուղղությունների մեջ




$$W = [v_1, v_2, \dots, v_k]$$

$$Z = Xc W$$

- $v_1, v_2, \dots$ սեփական վեկտորներն են՝ դասավորված մեծից փոքր λ -ով:
- Բաղադրիչները ուղղահայաց են և չկոռելացված:
- Նշանի փոփոխությունը չի փոխում PCA-ի իմաստը:

Որքա՞ն դիսպերսիա ենք պահում

Explained variance ratio-ը ցույց է տալիս պահված տեղեկության բաժինը PCA-ի չափանիշով



$$EVR_k = \lambda_k / \sum \lambda_r$$

- Կուտակային գիծը ցույց է տալիս՝ առաջին k բաղադրիչները միասին որքան դիսպերսիա են պահում:
- 90% շեմը կանոն է, ոչ օրենք:
- Կանխատեսման խնդրում k-ն ընտրում ենք validation-ով:

PCA-ի վեց քայլը

Ալգորիթմը, որը հիմա արդեն կարող ենք հասկանալ

1. Կենտրոնացնել տվյալները

2. Քննարկել սանդղակը / ստանդարտացումը

3. Հաշվել կովարիացիայի մատրիցը C

4. Գտնել C -ի սեփական արժեքներն ու վեկտորները

5. Ընտրել k բաղադրիչ

6. Պրոյեկտել՝ $Z = Xc W$

Քայլ 1. Կենտրոնացում

Յուրաքանչյուր հատկանիշից հանում ենք իր միջինը

$$\mu = (1/n) \sum_i X_i$$

$$X_{ci} = X_i - \mu$$

միջին կետը դառնում է սկզբնակետ

PCA-ի ենթատարածքը անցնում է տվյալների միջինով

- Եթե չենք կենտրոնացնում, առաջին առանցքը կարող է նկարագրել ոչ թե փոփոխությունը, այլ տվյալների միջինի հեռավորությունը զրոյից:

Քայլ 2. Կովարիացիայի մատրից

Հաշվում ենք՝ որ հատկանիշներն են միասին շարժվում

$$C = Xc^T Xc / (n - 1)$$

C-ի չափը $d \times d$ է

C-ն սիմետրիկ է

սեփական
արժեքները ≥ 0

- Անկյունագծում դիսպերսիաներն են:
- Անկյունագծից դուրս կովարիացիաներն են:
- Դրական կովարիացիան նշանակում է՝ մեծ արժեքները հաճախ միասին են:

Քայլ 3. սեփական տարրալուծում

Գտնում ենք C-ի հատուկ ուղղությունները

$$C v = \lambda v$$


v ՝ PCA առանցք

λ ՝ այդ առանցքի դիսպերսիա

- Սեփական արժեքները դասավորում ենք մեծից փոքր:
- Առաջին սեփական վեկտորը PC1-ն է:
- Երկրորդը PC2-ն է և ուղղահայաց է առաջինին:

Քայլ 4. ընտրել k բաղադրիչ

Կրճատման ուժը վերահսկում է k թիվը




- Փոքր $k \rightarrow$ ուժեղ սեղմում, բայց ավելի մեծ կորուստ:
- Մեծ $k \rightarrow$ ավելի շատ տեղեկություն, բայց ավելի քիչ կրճատում:
- Ընտրությունը կախված է նպատակներից՝
visualization, compression կամ prediction:

$$k < d$$

Քայլ 5. պրոյեկտել և ստանալ նոր աղյուսակ

Հին հատկանիշներից ստեղծում ենք նոր կոորդինատներ

$$Z = Xc W$$



- Z-ի տողերը նույն նմուշներն են, բայց նոր կոորդինատներով:
- Այս կոորդինատները կոչվում են PCA scores:

NumPy. կառուցում ենք PCA-ն

Նույն քայլերը կոդով

```
import numpy as np

X = np.array([[ 2,  2], [-2, -2], [1, -1], [-1, 1]],
              dtype=float)
mu = X.mean(axis=0)
Xc = X - mu
C = Xc.T @ Xc / (len(X) - 1)

values, vectors = np.linalg.eigh(C) # C- ն սիմետրիկ է
order = values.argsort()[::-1]
values = values[order]
vectors = vectors[:, order]

print(values)
print(vectors)
```

- axis=0 նշանակում է՝ միջինը հաշվել սյուներով:
- @ նշանը մատրիցների բազմապատկում է:
- eigh-ը հարմար է սիմետրիկ մատրիցների համար:

NumPy. պրոյեկցիա և վերականգնում


Պահում ենք միայն առաջին բաղադրիչը

```
k = 1
W = vectors[:, :k]
Z = Xc @ W
X_hat = Z @ W.T + mu

print('Z =')
print(Z.round(3))
print('reconstruction =')
print(X_hat.round(3))

print(np.allclose(W.T @ W, np.eye(k)))
```

- W -ի ձևը $d \times k$ է:
- Z -ի ձևը $n \times k$ է:
- X_hat -ը մոտավոր վերադարձ է սկզբնական տարածք:
- Պահել պետք է μ -ն և W -ն:



scikit-learn. Iris տվյալները


4 հատկանիշից ստանում ենք 2 բաղադրիչ՝ նկարելու համար

```
from sklearn.datasets import load_iris
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

iris = load_iris()
X, y = iris.data, iris.target


X_scaled = StandardScaler().fit_transform(X)
Z = PCA(n_components=2).fit_transform(X_scaled)

print(Z.shape) # (150, 2)
```



Պատկերի սեղմում PCA-ով

Քիչ բաղադրիչներ → ավելի մշուշոտ, շատ բաղադրիչներ → ավելի մոտ վերականգնում



- Յուրաքանչյուր պատկերը կարող ենք ներկայացնել k թվերով:
- Վերականգնված պատկերը նորից ունի նույն պիքսելների թիվը, բայց մանրամասները կարող են կորել:
- Պետք է պահել նաև միջինը և PCA բազիսը:

$64 \rightarrow k$ (այս օրինակում 8×8 պատկեր)

Կանխատեսման ժամանակ՝ կանխեք տվյալների արտահոսքը

PCA-ն նույնպես սովորում է պարամետրեր



fit միայն train-ի վրա, test-ը միայն transform

- Train/test բաժանումը արեք մինչև scaler/PCA fit-ը:
- Scaler-ը և PCA-ն fit արեք միայն train-ի վրա:
- Test-ի վրա միայն transform և վերջնական գնահատում:

Ե՞րբ PCA-ն բավարար չէ

PCA-ն հզոր է, բայց ունի սահմաններ

Գծային մեթոդ է

**զգայուն է
սանդղակին**

**արտանետումները
կարող են շեղել
առանցքները**

- Եթե տվյալները կորացած մակերևույթի վրա են, PCA-ն կարող է վատ ներկայացնել կառուցվածքը:
- Միայն visualization-ի համար հաճախ օգտագործվում են t-SNE կամ UMAP, բայց դրանք այլ նպատակ և այլ սահմանափակումներ ունեն:
- Եթե պետք է դասերը լավ բաժանել, PCA-ն միշտ լավագույն ընտրությունը չէ:

PCA = լավ առաջին քայլ, ոչ միշտ վերջնական լուծում

Ամփոփում և ելքի հարցեր

Դասի վերջում սովորողը պետք է կարողանա բացատրել այս 4 միտքը

1. Ո՞րն է տարբերությունը ռեգրեսիայի և դասակարգման միջև

2. Ինչո՞ւ է PCA-ն չվերահսկվող մեթոդ

3. Ինչպե՞ս է կովարիացիայի մատրիցը կապված PCA առանցքների հետ

4. Ի՞նչ է նշանակում “պահեցինք 90% դիսպերսիա”

**Մեծ գաղափար՝ շատ հատկանիշ → քիչ, իմաստալից
կոորդինատ**